


扩散模型的数学与前沿

从粒子动力学到科学计算与推理



陆一平 Yiping Lu

北京大学 北京国际数学研究中心 BICMR

扩散模型中的计算数学问题

01

分布怎样演化？

粒子行为 · Fokker Planck

02

怎样解决科学问题？

PDE · 薛定谔桥 · 输运

03

怎样学习动力学？

Flow matching · 离散扩散

04

怎样控制误差？

数值分析 · 统计复杂度

05

怎样改变生成目标？


Posterior · 推理时扩展

贯穿全程的问题

密度路径
动力学与计算代价

动力学怎样实现目标分布？有限计算又会带来哪些误差？

生成模型：从已有样本学习生成新样本




训练：学习如何去噪

生成：从随机噪声出发，求解生成方程

粒子操作一：Transport 改变位置

搬运：粒子数不变



$$\frac{dZ_s^i}{ds} = v_s(Z_s^i).$$

连续性方程


$$\partial_s \rho_s = -\nabla \cdot (v_s \rho_s).$$

可压缩速度场能够改变局部密度。

粒子按速度场搬运，整体密度满足连续性方程。

粒子操作二：Diffusion 加入随机扰动

独立重复试验的可能终点



$$dZ_s^i = \sqrt{2D_s} dW_s^i.$$


热方程

$$\partial_s \rho_s = D_s \Delta \rho_s.$$

单步位移尺度为 $\sqrt{\Delta s}$ 。

随机扰动使粒子散开；整体密度满足热方程。

粒子操作三：Death / Birth 改变相对质量



$$\partial_s \tilde{\rho}_s = V_s \tilde{\rho}_s, \quad \rho_s = \frac{\tilde{\rho}_s}{\int \tilde{\rho}_s}.$$

归一化选择方程


$$\partial_s \rho_s = (V_s - \mathbb{E}_{\rho_s} V_s) \rho_s.$$

增长势高于平均的区域，质量占比增加。

重加权改变质量分配；纯选择不能扩大分布的支撑。

三种粒子操作，对应一个密度方程

$$\partial_s \rho_s = \underbrace{-\nabla \cdot (v_s \rho_s)}_{\text{transport}} + \underbrace{D_s \Delta \rho_s}_{\text{diffusion}} + \underbrace{(V_s - \mathbb{E}_{\rho_s} V_s) \rho_s}_{\text{death / birth}}$$



一个时间步：先搬运，再扩散，再选择

标准生成模型

$V = 0$: ODE 或 SDE 推送概率分布

后续的条件生成与推理时扩展

$V \neq 0$: 引入权重、选择与粒子交互

分布演化方法在高维科学计算中的应用

高维 PDE



密度演化与半线性方程

随机最优控制



值函数与反馈控制

薛定谔桥



端点之间的最小相对熵路径

非平衡最优输运



质量输运与增减

平衡态与高维积分



Gibbs 采样与期望估计

反问题与不确定性



由观测得到后验样本

共同思路：以分布和动力学描述问题，用神经网络与粒子方法近似求解。


Simulation free: 训练时省去内层轨迹模拟

含义：计算训练损失时，无需先数值积分当前模型的动力学。

依赖轨迹的训练



Simulation free 训练



省去内层积分

减少训练中的多步网络调用。

训练时刻可并行

不同时间点可独立抽取。


省去轨迹反传

避免内层积分的离散误差及沿轨迹反向传播。

训练仍需抽样和局部计算；生成时通常仍需求解 ODE 或 SDE。

DDPM: 多步加噪, 可直接抽取单时刻样本


$$X_k = \sqrt{1 - \beta_k} X_{k-1} + \sqrt{\beta_k} Z_k, \quad Z_k \stackrel{\text{iid}}{\sim} \mathcal{N}(0, I).$$



$$X_k | X_0 \stackrel{d}{=} \sqrt{\bar{\alpha}_k} X_0 + \sqrt{1 - \bar{\alpha}_k} Z, \quad \bar{\alpha}_k = \prod_{j=1}^k (1 - \beta_j).$$

训练去噪器：监督信号就是刚刚加入的噪声

$$X_t = \alpha_t X_0 + \sigma_t Z, \quad Z \sim \mathcal{N}(0, I), \quad \mathcal{L}(\theta) = \mathbb{E}[\|w(t) \|\epsilon_\theta(t, X_t) - Z\|^2].$$



$$\epsilon^*(t, x) = \mathbb{E}[Z \mid X_t = x], \quad s^*(t, x) := -\frac{\epsilon^*(t, x)}{\sigma_t} = \nabla \log p_t(x).$$


Score 描述密度在局部如何变化

$$s^*(t, x) = \nabla_x \log p_t(x).$$

高斯加噪下的另一种解释

$$\mathbb{E}[\alpha_t X_0 \mid X_t = x] = x + \sigma_t^2 s^*(t, x).$$

无需知道密度，也能通过去噪学习 score。




Score 指向密度增大的方向；生成还需随时间调整动力学。

连续极限：用 SDE 描述从数据到噪声的过程

$$dX_t = b_t(X_t) dt + g_t dW_t, \quad X_0 \sim p_{\text{data}}, \quad t: 0 \rightarrow T.$$

粒子轨迹示意：漂移搬运，布朗运动扩散



$$\text{VP SDE:} \quad dX_t = -\frac{1}{2}\beta(t)X_t dt + \sqrt{\beta(t)} dW_t.$$

Fokker Planck: 从粒子运动到密度演化

粒子: Itô 公式
 $\varphi(X_t)$

取期望
分部积分

密度: 对偶方程
 $\partial_t p_t = \mathcal{L}_t^* p_t$

$$\frac{d}{dt} \mathbb{E} \varphi(X_t) = \mathbb{E} \left[\left(b_t \cdot \nabla \varphi + \frac{g_t^2}{2} \Delta \varphi \right) (X_t) \right].$$

前向 Kolmogorov 方程


$$\partial_t p_t = -\nabla \cdot (b_t p_t) + \frac{g_t^2}{2} \Delta p_t.$$

漂移对应一阶输运, 噪声对应二阶扩散。

用 Transport 重现 Diffusion 的密度演化

设 $p_t > 0$ 足够光滑, $D_t = g_t^2/2$ 仅依赖时间。

$$\Delta p_t = \nabla \cdot (\nabla p_t) = \nabla \cdot \underbrace{(p_t \nabla \log p_t)}_{\text{score}}.$$



$$\partial_t p_t = -\nabla \cdot \left[\underbrace{(b_t - D_t \nabla \log p_t)}_{v_t} p_t \right],$$

$$\dot{Z}_t = v_t(Z_t) \quad \text{probability flow ODE.}$$

扩散的概率通量为 $-D_t \nabla p_t$ 。
其速度就是 $-D_t \nabla \log p_t$ 。

精确 score、相同初值且适定时：每个时刻的分布相同，粒子路径不同。

反向 SDE: score 系数为何是 ODE 的两倍?

生成时钟 $s = T - t$, $\rho_s = p_{T-s}$; 记 $\bar{b}_s = b_{T-s}$, $\bar{D}_s = D_{T-s}$

$$\partial_s \rho_s = \nabla \cdot (\bar{b}_s \rho_s) - \bar{D}_s \Delta \rho_s = -\nabla \cdot [(-\bar{b}_s + \bar{D}_s \nabla \log \rho_s) \rho_s].$$

反向 probability flow

$$[-\bar{b}_s + \bar{D}_s \nabla \log \rho_s] ds$$

实现反向的密度演化

多加一份 score 输运

$$\bar{D}_s \nabla \log \rho_s ds$$

$$-\bar{D}_s \Delta \rho_s$$

—— 两项在密度方程中相消 ——

加入布朗扩散

$$\sqrt{2\bar{D}_s} d\bar{W}_s$$

$$+\bar{D}_s \Delta \rho_s$$

保留扩散后，反向漂移中的 score 系数变为 $2\bar{D}_s = g_{T-s}^2$

$$dY_s = \left[-\bar{b}_s(Y_s) + 2\bar{D}_s \nabla \log \rho_s(Y_s) \right] ds + \sqrt{2\bar{D}_s} d\bar{W}_s.$$

Flow matching: 直接学习搬运概率质量的速度

本节时间方向: $t = 0$ 为先验, $t = 1$ 为数据

$$\dot{Z}_t = v_t(Z_t), \quad \partial_t \rho_t + \nabla \cdot (\rho_t v_t) = 0.$$




$$\min_{\theta} \mathbb{E}_{t, C, X_t} [\|v_\theta(t, X_t) - u_t(X_t | C)\|^2].$$

训练用条件路径做回归；生成求解学到的 ODE。

线性插值：对条件速度取平均，得到生成速度场

$$(X_0, X_1) \sim \gamma, \quad X_t = (1 - t)X_0 + tX_1, \quad v_t(x) = \mathbb{E}[X_1 - X_0 \mid X_t = x].$$



为什么正确？

用链式法则，再取条件期望。


$$\frac{d}{dt} \mathbb{E}[\varphi(X_t)] = \mathbb{E}[\nabla \varphi(X_t) \cdot v_t(X_t)].$$

这就是连续性方程的弱形式。

端点耦合 γ 改变中间分布和速度场；独立配对一般不是最优输运。

Stochastic interpolants: 连接 flow 与 diffusion

$$X_t = l_t(X_0, X_1) + \eta(t)\xi, \quad \xi \sim \mathcal{N}(0, I), \quad \eta(0) = \eta(1) = 0.$$




$$-\nabla \cdot [\rho_t(v_t + \nu_t \nabla \log \rho_t)] + \nu_t \Delta \rho_t = -\nabla \cdot (\rho_t v_t).$$

加入噪声并补偿漂移，边际密度不变；路径分布仍然不同。

离散 diffusion: 把微分算子换成跳跃生成元

回到加噪方向: $t = 0$ 为数据, $t = T$ 为噪声

$$(L_t f)(x) = \sum_{y \neq x} q_t(x, y) [f(y) - f(x)], \quad q_t(x, y) \geq 0.$$



状态图示意: M 表示 mask

Master equation


概率的流入率减去流出率。

$$\dot{p}_t(x) = \sum_{y \neq x} \left[\underbrace{p_t(y) q_t(y, x)}_{\text{流入}} - \underbrace{p_t(x) q_t(x, y)}_{\text{流出}} \right].$$

常用局部跳跃: 每次只改一个 token。

反向跳跃率：离散世界的 score 是概率比

$$\bar{q}_s(x, y) = q_{T-s}(y, x) \frac{p_{T-s}(y)}{p_{T-s}(x)}, \quad s = T - t, \quad p_{T-s}(x) > 0.$$



连续状态： $\nabla \log p_t$

离散状态： $p_t(y)/p_t(x)$

SEDD 用 score entropy 学习正的概率比，再构造反向采样器。

Masked diffusion: 逐渐遮住, 再逐步恢复


$$\Pr(X_t^i = \cdot \mid X_0^i) = \alpha_t \delta_{X_0^i} + (1 - \alpha_t) \delta_M, \quad \alpha_0 = 1, \quad \alpha_T = 0.$$



给定数据, 正向各位置独立加噪; 反向恢复依赖整段上下文。

MDLM 的训练：对不同遮盖比例加权计算交叉熵

$$\mathcal{L}(\theta) = \int_0^T \underbrace{\frac{-\alpha'_t}{1 - \alpha_t}}_{w(t)} \mathbb{E} \left[\sum_{i: X_t^i = \text{M}} -\log p_\theta(X_0^i | X_t, t) \right] dt.$$



网络输入整段序列 损失只计入被遮盖位置

$$\alpha_t = 1 - t, \quad T = 1 \quad \Rightarrow \quad w(t) = 1/t.$$

在理想端点和 SUBS 参数化下，这是负对数似然的变分上界。

走向大语言模型：LLaDA 与 Dream 的两条训练路线

LLaDA：从头训练

随机初始化 → masked pretraining → SFT

双向 Transformer



学习多种 mask 比例下的条件预测

用扩散模型完成
语言预训练与指令跟随

Dream 7B：从 AR 模型初始化

预训练 AR → diffusion adaptation → SFT

保留 AR 的移位预测结构




噪声训练与上下文自适应调度

利用已有语言能力
再学习任意顺序的恢复

共同问题：模型预测哪些条件分布？采样器怎样把它们组合成一致的联合分布？


并行恢复：边际准确，还需保留位置间的相关性

$$p_0(AA) = p_0(BB) = \frac{1}{2} \quad \Rightarrow \quad \mathcal{L}(X_0 \mid X_T = MM) \neq \mathcal{L}(X_0^1 \mid X_T = MM) \otimes \mathcal{L}(X_0^2 \mid X_T = MM).$$



批量独立恢复通常有偏差；remask 或 corrector 需验证目标分布的不变性。

DLM 的数值问题：计算代价与采样误差



$$\text{NFE} = \text{网络调用次数}, \quad \text{token evaluations} = \sum_{k=1}^{\text{NFE}} \ell_k.$$

ℓ_k 是第 k 次调用处理的 token 数；实际耗时还取决于缓存、注意力与硬件。

理论分析一致性、离散化与混合；实验报告质量、NFE、token 计算量和延迟。

三种生成机制及其密度方程

连续确定性

$$\partial_t \rho = -\nabla \cdot (\rho \mathbf{v})$$

Flow matching / ODE

连续随机性

$$\partial_t \rho = \mathcal{L}^* \rho$$

Score / reverse SDE

离散跳跃

$$\dot{p} = Q^\top p$$

Discrete diffusion / DLM

学到生成动力学以后，误差从哪里来？应该把计算花在哪里？

两类问题：动力学算得准，分布学得好

固定早停时间 $\tau > 0$ ，先假定初始分布匹配。用同一个距离 d 比较四个分布。



先讲数值分析 固定模型，怎样选择求解器与步数 M ？

再讲统计复杂度 给定 m 个训练样本，模型能学到多准？

$$d(p_0, q_{\theta,M}) \leq \underbrace{d(p_0, p_\tau)}_{\text{平滑偏差}} + \underbrace{d(p_\tau, q_\theta)}_{\text{学习误差}} + \underbrace{d(q_\theta, q_{\theta,M})}_{\text{数值误差}}.$$


训练数据量 m 、采样步数 M 与独立生成轨迹数 N ，是三种不同资源。

固定学习动力学：局部残差如何传到终点？

固定空间 L_s Lipschitz 的学习场 $v_{\theta,s}$, $L \in L^1$ 。 y_s 为精确解, $\tilde{y}_s$ 为数值插值。

$$\dot{y}_s = v_{\theta,s}(y_s), \quad r_s := \dot{\tilde{y}}_s - v_{\theta,s}(\tilde{y}_s).$$

$$\|\tilde{y}_s - y_s\| \leq e^{\int_0^s L_a da} \|\tilde{y}_0 - y_0\| + \int_0^s e^{\int_u^s L_a da} \|r_u\| du.$$




误差传播示意； L_s 决定局部残差在后续演化中的放大

一致性控制局部残差，稳定性控制误差累积。比较格式时还要固定网络调用预算。

EDM：把模型表示与求解器设计分开

$$D_{\theta}(X, \sigma) = c_{\text{skip}}(\sigma)X + c_{\text{out}}(\sigma)F_{\theta}(c_{\text{in}}(\sigma)X, c_{\text{noise}}(\sigma)).$$



先固定去噪器，再比较时间参数化、网格和积分器。

以噪声 σ 为时间变量：怎样选采样网格？

$p_\sigma = p_0 * \mathcal{N}(0, \sigma^2 I)$; 去噪器 $D^*(x, \sigma) = \mathbb{E}[X_0 \mid X_0 + \sigma Z = x]$.

$$\nabla \log p_\sigma(x) = \frac{D^*(x, \sigma) - x}{\sigma^2}, \quad \frac{dx}{d\sigma} = \frac{x - D_\theta(x, \sigma)}{\sigma} \quad (\sigma_{\max} \rightarrow \sigma_{\min}).$$

$$\sigma_i = \left[\sigma_{\max}^{1/\rho} + \frac{i}{M-1} \left(\sigma_{\min}^{1/\rho} - \sigma_{\max}^{1/\rho} \right) \right]^\rho, \quad i = 0, \dots, M-1.$$




定性示意：在低噪声区加密节点；效果仍取决于模型与任务

Heun: 用预测点的斜率校正一步更新

记 $f_i = f_\theta(x_i, \sigma_i)$, $f_\theta(x, \sigma) = (x - D_\theta(x, \sigma))/\sigma$, $h_i < 0$ 。

$$x_i^E = x_i + h_i f_i, \quad x_{i+1} = x_i + \frac{h_i}{2} \left[f_i + f_\theta(x_i^E, \sigma_i + h_i) \right].$$



在固定 $\sigma_{\min} > 0$ 、足够光滑且稳定时，全局误差为 $O(\max_i |h_i|^2)$ 。

DPM Solver: 精确积分已知线性部分

概率流 ODE 可写成半线性形式, 使用局部递增时钟 τ :

$$\dot{x}_\tau = a(\tau)x_\tau + c(\tau)\epsilon_\theta(x_\tau, \tau), \quad \Phi(\tau, u) = \exp\left(\int_u^\tau a(v)dv\right).$$

$$x_{\tau_1} = \Phi(\tau_1, \tau_0)x_{\tau_0} + \int_{\tau_0}^{\tau_1} \Phi(\tau_1, u)c(u)\epsilon_\theta(x_u, u)du.$$



DPM Solver 进一步用半对数信噪比组织指数加权积分
平滑性与稳定性成立时, 得到一至三阶专用格式

高阶方法减小求解误差, 仍需另外控制网络带来的模型误差。

SDE 采样复杂度：给定 score 精度，需要多少步？

正向 OU: $dX_t = -X_t dt + \sqrt{2}dW_t$; q_h 为指数型离散的输出。

Chen, Chewi, Li, Li, Salim, Zhang, 2023

真实 score 全时段 L Lipschitz, $L \geq 1$; $m_2^2 = \mathbb{E}\|X_0\|^2 < \infty$; $\gamma = \mathcal{N}(0, I_d)$, $\text{KL}(p_0 \parallel \gamma) < \infty$; 各网格点的 $L^2(p_t)$ score 误差 $\leq \eta_0$

$$\text{TV}(q_h, p_0) \lesssim \underbrace{\sqrt{\text{KL}(p_0 \parallel \gamma)} e^{-T}}_{\text{先验失配}} + \underbrace{(L\sqrt{dh} + Lm_2h)\sqrt{T}}_{\text{离散误差}} + \underbrace{\eta\sqrt{T}}_{\text{score 误差}}, \quad h \lesssim L^{-1}.$$



在相应矩与熵条件下，步数 $M = \tilde{O}(L^2 d / \varepsilon^2)$ 。下一问：需要多少数据才能获得所需的 score 精度？

从有限训练样本出发：score 误差由什么决定？

真实 score 记为 s^* 。用 m 个独立数据样本，在网络类 $\mathcal{S}$ 中最小化加权去噪损失 $\mathcal{L}$ 。

$$\mathcal{R}(s) := \int_{\tau}^T g_t^2 \mathbb{E}_{p_t} \|s(t, X) - \nabla \log p_t(X)\|^2 dt = \mathcal{L}(s) - \mathcal{L}(s^*).$$

$$\mathcal{R}(\hat{s}_m) \leq \underbrace{\inf_{s \in \mathcal{S}} \mathcal{R}(s)}_{\text{逼近误差}} + 2 \underbrace{\sup_{s \in \mathcal{S}} |\hat{\mathcal{L}}_m(s) - \mathcal{L}(s)|}_{\text{统计估计误差}} + \underbrace{\Delta_{\text{opt}}}_{\text{优化误差}}.$$

表达能力

网络能否表示 score？

取决于数据结构与网络类

数据量

经验损失能否代表总体？

取决于样本数与函数类复杂度

优化

训练是否找到好的参数？


需要控制实际优化误差

减小训练损失需要同时控制泛化与优化。反复给同一数据加噪，不会增加独立数据量。

Girsanov: 把 score 学习误差转成分布误差

P : 精确反向 SDE, 初始 p_T ; Q_θ : 近似反向 SDE, 初始 π 。

$$\text{KL}(p_\tau \| q_{\theta, \tau}) \leq \text{KL}(P \| Q_\theta) = \text{KL}(p_T \| \pi) + \frac{1}{2} \int_\tau^T g_t^2 \mathbb{E}_{X \sim p_t} \|s_\theta(t, X) - \nabla \log p_t(X)\|^2 dt.$$



条件: 相同非退化扩散系数; $p_T \ll \pi$; Girsanov 指数为真鞅, 能量可积。

加权 score 风险给出 KL 上界, 再由 Pinsker 不等式得到 TV 误差。

样本复杂度：光滑性与维数怎样进入误差率？

OKO, AKIYAMA, SUZUKI ICML 2023

 m 个独立数据, $p_0 \in B_{\infty, \infty}^{\beta}([-1, 1]^d)$, $\beta > 0$ 。


紧支撑、支撑内正上下界、边界充分光滑。采用指定网络类的 ERM 与早停连续反向 SDE。

生成分布的统计误差

$$\mathbb{E}_{\mathcal{D}_m} \text{TV}(\hat{\mu}_m, p_0) \lesssim m^{-\frac{\beta}{2\beta+d}} (\log m)^8.$$

达到期望 TV 精度 ε 的数据量

$$m = \tilde{O}\left(\varepsilon^{-(2+d/\beta)}\right).$$

固定光滑性，维数越高越难学习
理论幂指数示意，略去对数因子

在这类密度上，统计率接近 minimax 最优。找到所需估计器的优化成本仍需另行分析。


低维数据：统计收益与端点奇异性

前页针对全维 Besov 密度。若 p_0 支撑在零 Lebesgue 测度的流形 $\mathcal{M}$ ，而 $q \ll \text{Leb}$ ：取 OU 加噪 $dX_t = -X_t dt + \sqrt{2} dW_t$ ， $m_2^2 = \mathbb{E}\|X_0\|^2 < \infty$ 。

$$\text{TV}(q, p_0) = 1, \quad W_2(p_\tau, p_0) \leq (1 - e^{-\tau})m_2 + \sqrt{d(1 - e^{-2\tau})}.$$

p_0 ：流形上的质量

p_τ ：流形附近的概率质量



小噪声示意；蓝点为加噪样本，背景色不是密度等高线

未知线性子空间模型可利用内在维数改善样本复杂度，但需要相应结构与正则性假设。

降低平滑偏差的同时，也要控制小噪声下的学习与积分误差。

少步生成：三类训练思路

路径几何



Rectified Flow / reflow 2023

重新配对端点，让生成轨迹更容易用少量步数积分

区间映射



Progressive Distillation (2022) Consistency (2023)

Shortcut, MeanFlow, Boffi et al. (2025)

通过教师蒸馏或自洽训练，用一次求值代替多步积分

输出分布



DMD SiD 2024


直接训练生成器，使输出分布接近目标分布

Boffi 等工作：从学习瞬时速度，到学习整段时间的流映射。

一步生成：直接学习整段流映射

本节约定：0 为噪声，1 为数据；考虑确定性概率流 $\dot{x}_t = b_t(x_t)$ 。

$$\Phi_{s,t}(x_s) = x_t, \quad \hat{X}_1 = \Phi_{0,1}^\theta(Z), \quad Z \sim \rho_0.$$




$$f_s(x_s) = f_t(x_t), \quad f_1(x) = x.$$

Consistency model 预测固定终点，flow map 描述任意时间区间的演化。

同一个网络同时学习瞬时速度与流映射

用端点样本直接构造 $I_t = (1 - t)X_0 + tX_1$ ，其中 $X_0 \sim \rho_0$ 、 $X_1 \sim \rho_1$ 。

$$\Phi_{s,t}^\theta(x) = x + (t - s)v_{s,t}^\theta(x), \quad v_{t,t}^*(x) = b_t(x) = \mathbb{E}[X_1 - X_0 \mid I_t = x].$$



速度的监督: FLOW MATCHING

$$\mathcal{L}_{\text{diag}}(\theta) = \mathbb{E} \|v_{t,t}^\theta(I_t) - (X_1 - X_0)\|^2.$$

对角线上的回归学习瞬时速度。

区间内的 $v_{s,t}$ 表示沿轨迹的平均速度。

参数化保证恒等边界，数据回归确定自蒸馏所需的速度场。

流映射的三种自治条件

在光滑性、ODE 唯一性、恒等边界和正确对角速度下：

$$\text{Lagrangian: } \partial_t \Phi_{s,t}(x) = b_t(\Phi_{s,t}(x)),$$

$$\text{Eulerian: } \partial_s \Phi_{s,t}(x) + D_x \Phi_{s,t}(x) b_s(x) = 0,$$

$$\text{Composition: } \Phi_{s,t} = \Phi_{u,t} \circ \Phi_{s,u}, \quad s < u < t.$$




三种等式给出三种自蒸馏方法，刻画同一流映射，但优化过程不同。

LSD: 用网络自身的速度预测训练流映射

直接抽取 (X_0, X_1, s, t) , $s < t$; 构造 l_s , 记 $\hat{b}_t = v_{t,t}^\theta$, $\lambda > 0$ 。

$$\mathcal{L}_{\text{train}} = \mathcal{L}_{\text{diag}} + \lambda \mathbb{E} \left\| \partial_t \Phi_{s,t}^\theta(l_s) - \text{sg} \left[\hat{b}_t \left(\Phi_{s,t}^\theta(l_s) \right) \right] \right\|^2.$$

在线教师: sg 停止梯度



无需预训练教师或逐步模拟训练轨迹，仍需计算时间导数并反向传播。

固定生成器，按观测或奖励改变目标分布

此前：学习生成器

$$Z \sim p_{\text{prior}} \mapsto X \sim p_{\text{pre}}.$$

训练确定模型，求解器近似采样。

接下来：按目标生成

$$\pi(x) \propto p_{\text{pre}}(x) \ell(x).$$

观测、约束或 reward 决定新目标。

预训练生成器

引导与粒子选择

校正采样偏差

本节约定： $t = 0$ 是噪声先验， $t = T$ 是输出数据。

后验采样、奖励引导与成功样本搜索

本节生成时钟: $t = 0$ 噪声先验, $t = T$ 数据端

$$\pi(x) = \frac{p_{\text{pre}}(x) \ell(x)}{Z}, \quad \ell(x) = p(y | x) \text{ 或 } e^{\beta r(x)}.$$

Posterior sampling

观测 y 的条件分布
刻画后验不确定性

Reward tilting

偏好与多样性权衡
 β 控制集中程度

Max reward search

找到一个成功样本
 $A = \{r \geq r_*\}$

$$X^{1:M} \stackrel{\text{iid}}{\sim} \pi \quad \Rightarrow \quad \mathbb{P}\{\exists i : X^i \in A\} = 1 - (1 - \pi(A))^M.$$

采样关注整个分布的误差, 搜索关注找到成功样本的概率。

Reward guidance: Is José at work?

假设模型能够生成 José 的图像，现在希望让他出现在工作场景中。

基础分布：人物与不同场景



Reward model Is José at work?

$$r(x) = \Pr_{\phi}(\text{at work} \mid x)$$

用 Doob value 引导生成
 $a_t \nabla G_t(X_t), \quad G_t \approx \log h_t$

期望的生成场景



AI 合成示意：José at work

Reward 表达对工作场景的偏好，guidance 使生成过程更倾向这类图像。

Doob guidance: 从终端奖励到中途引导

当前状态的 Doob value

给定当前噪声状态，对终端奖励势取条件平均：

$$h_t(x) = \mathbb{E}_{\mathbb{P}}[e^{\beta r(X_T)} \mid X_t = x].$$

可用未来模拟估计，计算量可能较大。


理想 Doob 漂移修正

$$a_t \nabla \log h_t(x), \quad a_t = \sigma_t \sigma_t^\top.$$

实际 guidance

用 $G_t \approx \log h_t$ ，加入漂移 $a_t \nabla G_t$ 。

近似 value 可能引入采样偏差，需要进一步校正。



Reward 评价终点。


Value 引导路径。

SMC 可校正引导偏差，有限粒子仍有误差。

Doob value 可以怎样计算？从当前状态模拟未来

从 $X_t = x$ 出发，沿基础模型 P 独立模拟 M 条未来轨迹。

$$h_t(x) = \mathbb{E}_P[\ell(X_T) \mid X_t = x], \quad \hat{h}_t(x) = \frac{1}{M} \sum_{m=1}^M \ell(X_T^{(m)}).$$



模拟未来可以估计 value；完整 rollout 的代价，是每次都要生成到终点。

DOIT: 对转移核求导, 只查询奖励值

QIJIE ZHU, ZEQI YE, HAN LIU, ZHAORAN WANG, MINSHUO CHEN ICML 2026

本页 h_k 指离散生成器的 value; $\varphi_k(z | x)$ 为一步转移密度, $\eta_k > 0$ 。

$$\nabla h_k(x) = \mathbb{E}_P \left[\ell(X_T) \nabla_x \log \varphi_k(X_{t_{k+1}} | x) \mid X_{t_k} = x \right].$$

$$\hat{g}_k(x) = \frac{M^{-1} \sum_{m=1}^M \ell(X_T^{(m)}) \nabla_x \log \varphi_k(X_{t_{k+1}}^{(m)} | x)}{\hat{h}_k(x) \vee \eta_k}, \quad \text{漂移修正} \approx a_{t_k} \hat{g}_k.$$

Proto: 完整模拟未来

从每个候选继续生成到终点。
论文在相应假设下给出分布误差界。

Practical: 用去噪估计替代终点


一步前瞻, 复用当前 score。
更省计算, 但另有代理近似误差。

无需奖励梯度或额外训练; 仍需转移核对输入的导数, 有限样本比值一般有偏差。

SVDD: 每条轨迹按 soft value 选择下一步

LI ET AL., NEURIPS 2025 值查询同时适用于连续和离散状态

$$P_k^H(dz | x) = \frac{P_k(dz | x) H_{k+1}(z)}{P_k H_{k+1}(x)}, \quad H_k = e^{v_k / \alpha}.$$



有限候选 K : 自归一化选择通常仍有偏差


$$Z_i \stackrel{\text{iid}}{\sim} P_k(\cdot | x), \quad \mathbb{P}(J = i | Z_{1:K}) = \frac{H_{k+1}(Z_i)}{\sum_j H_{k+1}(Z_j)}.$$

专家相乘后，需要增加生灭项

Feynman Kac Correctors Skreta et al., ICML 2025

先看两个正、光滑的热方程解； $D_t \geq 0$ 仅依赖时间。

$$\begin{aligned}\partial_t p_t &= D_t \Delta p_t, & \partial_t q_t &= D_t \Delta q_t, & \tilde{\rho}_t &= p_t q_t, \\ \partial_t \tilde{\rho}_t &= D_t \Delta \tilde{\rho}_t + \underbrace{(-2D_t \nabla \log p_t \cdot \nabla \log q_t)}_{V_t: \text{乘积带来的反应势}} \tilde{\rho}_t.\end{aligned}$$



同一时刻的密度形状示意；乘积强调两个专家共同支持的区域


热方程的解相乘，一般不再满足原热方程；补上反应势后，仍是扩散加生灭。

从组合密度到三种粒子操作

各专家满足同类 PDE。取 $\mathcal{L}_t^* \rho = -\nabla \cdot (b_t \rho) + D_t \Delta \rho$ ，乘积的余项仍是反应势。

$$\tilde{\rho}_t = \prod_j p_{j,t}^{\lambda_j}, \quad V_t = \frac{\partial_t \tilde{\rho}_t - \mathcal{L}_t^* \tilde{\rho}_t}{\tilde{\rho}_t}.$$

$$\partial_t \rho_t = \underbrace{-\nabla \cdot (b_t \rho_t)}_{\text{transport}} + \underbrace{D_t \Delta \rho_t}_{\text{diffusion}} + \underbrace{(V_t - \mathbb{E}_{\rho_t} V_t) \rho_t}_{\text{death / birth}}, \quad \rho_t = \frac{\tilde{\rho}_t}{\int \tilde{\rho}_t}.$$




组合后仍保留这三种操作，可用加权粒子与重采样近似模拟。

FK Steering: 把终端奖励分解为逐步权重

TDS: 后验条件采样, 2023 FK STEERING: 奖励引导, 2025

$$H_0(X_0) \prod_{k=0}^{n-1} \frac{H_{k+1}(X_{k+1})}{H_k(X_k)} = \ell(X_n), \quad H_n = \ell.$$



颜色记录祖先；复制后的噪声独立。示意图

中间势函数引导粒子选择，完整路径权重决定最终采样目标。

URGE: 在路径空间做 Girsanov 校正

WANG, WANG, REN, BLANCHET, LU ICML 2026

$$\mathbb{P}: dX_t = b_t dt + \sigma_t dW_t, \quad \mathbb{Q}: dX_t = (b_t + \sigma_t u_t) dt + \sigma_t dW_t^{\mathbb{Q}}.$$

同一起始分布下的完整路径权重

$$R(X) = \ell(X_T) \exp \left\{ - \int_0^T u_t^\top dW_t^{\mathbb{Q}} - \frac{1}{2} \int_0^T \|u_t\|^2 dt \right\}.$$

满足条件的引导 u
提出有希望的路径

记录噪声与控制
累计路径似然比

周期性重采样
校正提议分布


校正权重无需 reward 的梯度或 Hessian, 引导本身仍有计算代价。

URGE: 路径权重怎样变成边缘权重?

$\mathbb{P}$ 为基础路径法则, $\mathbb{Q}$ 为引导路径法则; $Z = \mathbb{E}_{\mathbb{P}}[\ell(X_T)] \in (0, \infty)$ 。

$$R_T(X_{0:T}) = \ell(X_T) \frac{d\mathbb{P}}{d\mathbb{Q}}(X_{0:T}).$$

Pathwise: 权重依赖整条历史



相同终点, 不同历史: 条件路径示意

给定 $X_T = x$
按 $\mathbb{Q}$ 对历史
取条件平均


Particlewise: 只看终点

边缘权重
校正终点分布

$$\frac{d\pi}{d\mathbb{Q}_T}(x) = \frac{1}{Z} \mathbb{E}_{\mathbb{Q}}[R_T | X_T = x].$$

精确加权得到同一终端分布, 路径方法无需显式计算条件平均。

ESS 无法反映共同祖先造成的相关性



中性 Brownian 反例

每个粒子的终端边缘都是 $\mathcal{N}(0, 1)$ 。
局部 ESS = N ，但粒子之间相关。


$$\text{MSE} \left(\frac{1}{N} \sum_i f(X_n^i) \right) \geq c \min \left\{ \frac{n}{N}, 1 \right\}.$$

$$\text{RMSE} \leq \varepsilon < \sqrt{c} \Rightarrow N = \Omega(n\varepsilon^{-2}), \quad \text{work} = \Omega(n^2\varepsilon^{-2}).$$

下界针对每步全量重采样；不能外推到所有自适应 SMC。

逐条路径拒绝采样：不复制其他路径的祖先


SMC：跨路径复制父粒子



多个后代可以继承同一段历史

$$A_k^i \sim \text{Cat}(W_{k-1}^{1:N}), \quad X_k^i \sim P_{k-1}(X_{k-1}^{A_k^i}, \cdot)$$

CHILD REJECTION：只重试当前子步



拒绝后保留当前前缀，只重试这一步

$$Y \sim P_k(x, \cdot), \quad U \sim \text{Unif}(0, 1)$$

$$\text{接受条件: } U \leq \frac{H_{k+1}(Y)}{M_k(x)}$$

$M_k(x)$ 是已知有效上界： $0 < H_{k+1}(y) \leq M_k(x)$ 。

独立重跑整个路径采样器，就不产生跨路径的共同祖先。

近似 value 留下路径权重，再用外层 MH 校正

固定起点 $X_0 = x_0$ ；离散基准转移 P_k ；终端势 $H_n = \ell > 0$

$$Q_k^H(x, dy) = \frac{P_k(x, dy) H_{k+1}(y)}{(P_k H_{k+1})(x)}, \quad Q^H = \prod_{k=0}^{n-1} Q_k^H.$$

$$R(X_{0:n}) = \frac{\ell(X_n) d\mathbb{P}_n}{dQ^H}(X_{0:n}) = H_0(x_0) \prod_{k=0}^{n-1} \frac{(P_k H_{k+1})(X_k)}{H_k(X_k)}.$$

精确 value：局部采样已足够

$H_k = P_k H_{k+1}$ ，所以 $R = H_0(x_0)$ 。
终端分布就是目标。

SMC 保留这些增量权重；只做局部拒绝，会遗漏完整路径的校正。

近似 value：父状态因子仍在

相邻 H 相消，剩余比值一般不消。
外层 MH 以 $1 \wedge R'/R$ 接受新路径。

改用增广候选池提议后，可显式计算它的路径权重。

Stein 恒等式：用值查询估计引导方向

直接微分路线

Doob 引导需要 $\nabla \log H$ 。

局部 PDE 缺陷还可能需 $\partial_t H$ 与 $\text{Tr}(a \nabla^2 H)$ 。

— 值 ——— 梯度 ——— Hessian
高阶导数增加计算成本

高斯分部积分： $Z \sim \mathcal{N}(0, I)$


$$\begin{aligned} \frac{1}{\sqrt{\delta}} \mathbb{E}[ZH(\mu + \sqrt{\delta} \sigma Z)] \\ = \sigma^\top \mathbb{E}[\nabla H(\mu + \sqrt{\delta} \sigma Z)]. \end{aligned}$$

关键一步：把引导的导数计算转成局部值查询。

接下来的问题：怎样同时得到低方差引导与可计算的校正权重？

分部积分把导数换成值的期望；用于归一化引导的有限样本比值一般有偏差。

Two Queries: 用两次值查询近似 Doob 漂移




$$\mathbb{E}[Y^J | x] = x + \delta(b + a \nabla \log H)(x) + o(\delta).$$

$$S = \frac{H^+ + H^-}{2}, \quad \text{Var}\left(\frac{S}{\mathbb{E}S}\right) = O(\delta^2).$$

两点的值差决定引导方向，平均值抵消一阶随机扰动。

Stein pool: 一条轨迹内的并行值查询

$$Z_i = \sqrt{\frac{K}{K-1}}(G_i - \bar{G}), \quad G_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, I), \quad \sum_i Z_i = 0.$$



各方向均为标准高斯，总和为零

候选值的平均与方差

$$H_i = H(\mu + \sqrt{\delta} \sigma Z_i), \quad S = K^{-1} \sum_i H_i.$$

$$\text{Var}\left(\frac{S}{\mathbb{E}S}\right) \leq \frac{\delta^2 \mathcal{C}_2^2}{2(K-1)}.$$


按 H_i 归一化选择一个候选。

$K = 2$ 恰好回到对称的 Two Queries。

保留候选池，计算完整路径的校正权重

原始候选池（无局部 MH）：保留增广状态，得到可计算的路径权重

$$R = \ell(X_n) \prod_{k=0}^{n-1} \frac{S_k}{H_{k+1}(X_{k+1})} = H_0(X_0) \prod_{k=0}^{n-1} \frac{S_k}{H_k(X_k)}, \quad H_n = \ell.$$



$$\hat{\pi}_N(f) = \frac{\sum_{i=1}^N R_i f(X_n^i)}{\sum_{i=1}^N R_i}, \quad \{\text{完整提议路径 } i\}_{i=1}^N \text{ 相互独立.}$$

权重恒等式是精确的，有限 N 的自归一化估计一般仍有偏差。

外层 MH：校正有限候选与近似 value 的偏差

$$\omega' \sim Q_{\text{aug}}, \quad \alpha(\omega, \omega') = 1 \wedge \frac{R(\omega')}{R(\omega)}.$$

当前路径



新提议路径



按完整权重比较
接受新路径
或保留当前路径

每个独立输出，可以重新运行一条外层链

$$\frac{d\Pi_{\text{aug}}}{dQ_{\text{aug}}} \leq M \quad \Rightarrow \quad \|\nu K_{\text{MH}}^m - \Pi_{\text{aug}}\|_{\text{TV}} \leq (1 - M^{-1})^m.$$

不变分布正确，仍需控制有限步混合误差，其大小取决于路径权重。

独立路径误差界：步数与轨迹数的关系

离散目标 π_n , $0 \leq f \leq 1$, 固定起点; 满足手稿的矩与曲率条件

研究稿：独立路径的 SNIS 界

$$\text{MSE} \leq \frac{8e^\Delta}{N}, \quad \Delta \leq 4A + \frac{C_2^2 T \delta}{2(K-1)}.$$

A : 累计 Bellman 缺陷。

若 A, C_2 对网格一致有界, 固定 K 即可保持 $N = O(\varepsilon^{-2})$ 。

固定每条轨迹查询预算 $B = nK$

$$\frac{n\delta^2}{K-1} = \frac{T^2}{B} \frac{K}{K-1}, \quad \delta = T/n.$$

增加候选数的主要优势是并行查询。

固定 B 时, 候选池噪声的误差界保持同阶。

条件一致成立时, 加密网格不要求同步增加独立轨迹数。

计算数学中的研究机会

分布与几何

薛定谔桥、非平衡输运

怎样学习受物理约束的路径？

数值与误差控制

刚性、网格、指数积分

局部误差能否指导全局预算？

离散与并行计算

跳跃过程、相关性、重遮盖

怎样量化并行更新的偏差？

推断与计算复杂度

值函数、粒子系统、路径校正

怎样量化额外计算的收益？

回到今天的主线

用可学习的动力学，把简单分布变成复杂分布。

SDE、ODE 与跳跃过程描述不同的生成机制。

学习误差、离散误差与统计误差需要分别控制。

引导帮助探索，校正控制剩余的采样偏差。

Questions?

陆一平 BICMR, Peking University yipinglu@bicmr.pku.edu.cn

Rectified flow: 重新配对, 让生成路径更容易积分




$$\gamma_{\text{new}} = \mathcal{L}(Z_0, Z_1), \quad \mathbb{E} c(Z_1 - Z_0) \leq \mathbb{E} c(X_1 - X_0) \quad (\text{凸函数 } c, \text{ 理想精确设定}).$$

路径变直有利于大步长；一步采样质量仍受回归误差与离散化误差影响。

D3PM: 先决定如何给离散数据加噪

$$K_k(x, y) = \Pr(X_k = y \mid X_{k-1} = x), \quad \Pr(X_k = \cdot \mid X_0 = x) = e_x^\top K_1 \cdots K_k.$$


均匀替换



局部替换



吸收掩码




D3PM 用转移核描述加噪；absorbing mask 是其中一种选择。

Score 学习：低维结构如何减少样本需求？

$X_0 = AZ \in \mathbb{R}^d$, $A^\top A = I_r$, $r \ll d$: 未知线性子空间模型。

样本数 n , 早停时间 $\varepsilon > 0$



结构示意图

$$\mathcal{R}_n = \frac{1}{T - \varepsilon} \int_{\varepsilon}^T \mathbb{E}_{X \sim p_t} \|\hat{S}(t, X) - \nabla \log p_t(X)\|^2 dt,$$

$$\mathcal{R}_n = \tilde{O} \left[\frac{1}{\varepsilon} \left(n^{-\frac{2}{r+5}} + d n^{-\frac{r+3}{r+5}} \right) \right].$$


潜在密度光滑且有高斯型尾界，潜在 score 为 Lipschitz；使用适配结构的网络类做经验风险最小化。

样本数的主要指数由内在维数 r 决定；常数与余项仍含环境维数 d 。

随机 corrector 如何修正采样分布？

固定噪声层级 $\sigma > 0$ ，用辅助时间 τ 运行 Langevin：

$$dZ_\tau = \nabla \log p_\sigma(Z_\tau) d\tau + \sqrt{2} dB_\tau, \quad -\nabla \cdot (p_\sigma \nabla \log p_\sigma) + \Delta p_\sigma = 0.$$



精确 score 与连续 Langevin：保持目标分布
学习 score 与有限步长：仍有模型与离散偏差


近似 score 下，SDE 与 ODE 的输出可能不同；加入随机性不保证精确校正。

流映射误差：要控制从先验出发的映射路径

真实流的速度为 b_t ，边缘密度为 ρ_t ； $\hat{b}_t = v_{t,t}^\theta$ 对空间一致 L Lipschitz, $L \geq 0$ 。令 $G_t = \Phi_{0,t}^\theta(Z)$, $Z \sim \rho_0$ ；假设流存在， $G_0 = Z$, G_t 绝对连续且二阶矩有限。


$$E_{\text{diag}} = \int_0^1 \mathbb{E}_{X \sim \rho_t} \|\hat{b}_t(X) - b_t(X)\|^2 dt,$$

$$E_{\text{map}} = \int_0^1 \mathbb{E}_{Z \sim \rho_0} \|\dot{G}_t - \hat{b}_t(G_t)\|^2 dt.$$



E_{diag} 是 FM excess risk； E_{map} 专门控制 $s = 0$ 的映射路径。


更多计算，分别用在哪些地方？




同时报告：模型调用数、奖励调用数、延迟与内存

求解误差、引导偏差、粒子方差与混合误差，需要分别控制。

URGE 实验：校正分布与增加粒子数




30 维 Gaussian mixture
二维投影展示；报告 MMD 0.06



SD v1.5 实验结果


在所报告的设置下，增加粒子数提高了 ImageReward。
改进幅度依赖任务与预算。

数值结果：改善引导，再校正采样偏差



$21.8\times$

$d = 64, K = 8$: 报告的引导 MSE 改善



错设值函数：原始 proposal 0.7282


加权后 0.6624；目标矩 $2/3$

近似值将轨迹引向有希望的区域；额外校正控制剩余偏差。

从候选池的局部矩，控制完整路径权重

原始候选池，固定起点 $X_0 = x_*$ ； $H_k > 0$ ， $H_n = \ell$ 。令 $G_k = P_k H_{k+1}$ ， $T_k = S_k / G_k(X_k)$ ， $A = \sum_k a_k$ 。

$$\mathbb{E}[T_k | \mathcal{F}_k] = 1, \quad \mathbb{E}[T_k^2 | \mathcal{F}_k] \leq 1 + v_k, \quad |\log(G_k/H_k)| \leq a_k.$$



$$\mathbb{E}M_n^2 \leq \prod_k (1 + v_k), \quad \mathbb{E}w^2 \leq e^{4A} \prod_k (1 + v_k) \leq \exp\left(4A + \sum_k v_k\right).$$

a_k, v_k 是确定性上界；若 $v_k \leq \delta_k^2 C_2^2 / [2(K-1)]$ ，则噪声按 $\sum_k \delta_k^2$ 累积。

SNIS 误差界：用权重的二阶矩控制均方误差

完整提议路径相互独立， $w_i > 0$ ， $\mathbb{E}w_i = 1$ ， $\text{osc}(f) \leq 1$ ； $\mu = \pi_n(f)$ ， $\bar{w}_N = N^{-1} \sum_i w_{i0}$

$$\hat{\mu} - \mu = \frac{A_N}{\bar{w}_N}, \quad A_N = \frac{1}{N} \sum_{i=1}^N w_i(f_i - \mu), \quad \mathbb{E}A_N^2 \leq \frac{\mathbb{E}w^2}{N}.$$

事件 $\bar{w}_N \geq 1/2$

误差平方 $\leq 4A_N^2$

事件 $\bar{w}_N < 1/2$

误差平方 ≤ 1 ，概率用 Chebyshev 控制

$$\mathbb{E}(\hat{\mu} - \mu)^2 \leq \frac{4\mathbb{E}w^2 + 4\text{Var}(w)}{N} \leq \frac{8\mathbb{E}w^2}{N} \leq \frac{8\exp(4A + \sum_k v_k)}{N}.$$

此界针对离散目标 π_n ；时间离散偏差与有限步 MH 的混合误差须另行控制。

Diffusion: 去噪回归怎样变成生成器?

代表论文	主要贡献	条件与局限
Diffusion Models Sohl Dickstein et al., ICML 2015	固定加噪链, 学习反向链	仍有反向近似误差与多步成本
多尺度 score 与 NCSN Song, Ermon, NeurIPS 2019	多层噪声训练, 退火 Langevin 生成	有限迭代未必充分混合
DDPM Ho, Jain, Abbeel, NeurIPS 2020	加噪边缘有闭式, 直接回归噪声	简化损失采用特定权重
Score SDE Song et al., ICLR 2021	反向 SDE 与 probability flow ODE	边缘分布等价依赖精确 score
DDIM Song, Meng, Ermon, ICLR 2021	复用去噪网络, 改变采样动力学	有限步跳跃仍有采样误差

Flow：怎样设计训练目标、端点配对与随机性？

代表论文	主要贡献	条件与局限
Flow Matching Lipman et al., ICLR 2023	回归条件速度，训练无需展开轨迹	生成通常仍需求解 ODE
Rectified Flow Liu, Gong, Liu, ICLR 2023	通过 reflow 改变耦合与轨迹几何	条件路径为直线，生成轨迹未必
Interpolant Flows Albergo et al., ICLR 2023	先指定插值，再回归概率流速度	插值路径未必最优
OT CFM Tong et al., TMLR 2024	用端点 OT 耦合设计回归路径	小批量 OT 只是全局 OT 的近似
Stochastic Interpolants Albergo et al., JMLR 2025	同一密度路径，选择 ODE 或 SDE	改变噪声须同时补偿漂移

离散生成：怎样学习跳跃过程？

代表论文	主要贡献	条件与局限
D3PM Austin et al., NeurIPS 2021	用结构化转移矩阵 定义符号的加噪过程	mask 是一种选择 并非唯一的离散噪声
CTMC Discrete Denoising Campbell et al., NeurIPS 2022	从转移矩阵到生成元 分析反向率与数值采样	tau leaping 有离散化误差 学习的跳跃率另有模型误差
SEDD Lou, Meng, Ermon, ICML 2024	以 score entropy 学相邻状态的概率比	正的跳跃率保证过程合法 不保证全局概率比相容
Masked Diffusion (MDLM) Sahoo et al., NeurIPS 2024	利用吸收态结构 化简为带权 mask 交叉熵	推导依赖 SUBS 与端点 并行恢复仍需误差分析
Discrete Flow Matching Gat et al., NeurIPS 2024	指定条件概率路径 用端点后验构造跳跃率	生成仍然是随机跳跃 有限步近似仍需数值分析

语言模型前沿：规模、计算结构与理论保证

代表论文	主要贡献	条件与局限
LLaDA Nie et al., NeurIPS 2025	从头完成扩散预训练 与指令微调	验证大规模训练可行 不代表普遍优于 AR
Dream 7B Ye et al., 2025 预印本	复用 AR 权重与移位预测 再做扩散适配	初始化与数据预算不同 性能差异不能只归因于范式
Block Diffusion Arriola et al., ICLR 2025	块间顺序，块内并行 支持前缀 KV 缓存	块大小影响方差与计算 NFE 少不等于延迟低
Optimal Parallel Samplers Jiang et al., ICLR 2026	CoT 对应并行计算步骤 修改 token 可复用中间存储	结论针对电路表达能力 需计入 CoT 与轮内计算
MDM VGB Jeon, Vuong, Tao, 2026 预印本	用 verifier 引导回溯 给出目标分布与混合保证	一致乘性 verifier 误差界 目标条件于全揭示状态

数值分析文献：怎样降低求解代价？

代表论文	主要贡献	条件与局限
DDIM Song et al. • ICLR 2021	保留训练目标，改变采样路径	少步输出仍有离散误差
EDM Karras et al. • NeurIPS 2022	分别设计预条件、网格与积分器	实验支持特定组合，不保证普适最优
DPM Solver Lu et al. • NeurIPS 2022	精确积分线性项，近似网络积分	高阶精度需要正则性；模型误差仍在
DPM Solver++ Lu et al. • MIR 2025	数据预测、多步法改善引导采样	强 guidance 仍会改变稳定性
UniPC Zhao et al. • NeurIPS 2023	统一高阶预测与校正	复用历史求值提高阶数；仍需正则性

数值分析文献：给定 score 精度的采样复杂度

代表论文	主要贡献	条件与局限
Score to Sampling Chen et al. • ICLR 2023	把训练的平方误差转成采样界	这里的基础定理要求 Lipschitz score
Nearly d Linear Bounds Benton et al. • ICLR 2024	有限二阶矩下，步数近线性依赖维数	目标经过早停平滑；准确 score 已给定
DDPM Rate: $O(d/M)$ Li, Yan • JMLR 2025	改进 DDPM 的全变差离散误差界	比较 p_{X_1} 与 p_{Y_1} ；仍有 score 项
Diffusion on Manifolds De Bortoli • TMLR 2022	处理低维支撑和终点奇异性	距离、早停与几何假设决定结论

统计复杂度文献：样本量、数据结构与泛化

代表论文	主要贡献	条件与局限
Minimax Estimation Oko et al. • ICML 2023	Besov 类下连接估计误差与分布恢复	依赖指定的经验风险最小化估计器
Low Dimensional Data Chen et al. • ICML 2023	利用未知线性子空间的内在维数	特定低维模型；不涵盖任意流形
Dynamical Regimes Biroli et al. • 2024	精确经验 score 的结构形成与记忆	高维理想分析；不是任意网络训练定理
Training and Memorization Bonnaire et al. • NeurIPS 2025	训练动力学可分离泛化与记忆时间	理论针对随机特征模型；深网由实验支持

少步生成的起点：压缩更新、改变路径、匹配分布

代表论文

主要贡献

条件与局限

Progressive Distillation

Salimans & Ho, ICLR 2022

教师两次更新，蒸馏为学生一次更新

需要预训练教师与多轮蒸馏

Rectified Flow / reflow

Liu, Gong & Liu, ICLR 2023

重新配对并训练速度，使轨迹趋直

条件路径为直线，边缘轨迹未必

Consistency Models

Song et al., ICML 2023

同一概率流轨迹上，端点预测一致

区分蒸馏与直接训练；多步可再加噪

DMD

Yin et al., CVPR 2024

用目标与生成分布的 score 差作监督

须估计生成分布；原版仍含配对回归

流映射的发展：任意区间、平均速度与自蒸馏

代表论文

主要贡献

条件与局限

Flow Map Matching

Boffi et al., TMLR 2025

用两时间映射连接 PDE 与 ODE 描述

关注解算子；不涵盖所有分布匹配目标

Shortcut Models

Frans et al., ICLR 2025

零步长回归；用两次短步监督一次长步

存在自举误差与额外网络求值

MeanFlow

Geng et al., NeurIPS 2025

区间平均速度满足微分恒等式

总导数 JVP 包含空间与时间方向

Self Distillation

Boffi et al., NeurIPS 2025

对角学习速度；非对角自蒸馏映射

刻画同一流映射；优化行为不同

推理文献一：条件生成、后验采样与搜索

代表论文

主要贡献

条件与局限

Classifier Free Guidance

Ho, Salimans, 2022

混合条件与无条件预测
调节条件生成的强度

需要相应训练；混合 score
未必实现指定密度曲线

DDRM

Kawar et al., NeurIPS 2022

在观测算子的谱坐标中
结合测量与预训练去噪器

主要针对线性逆问题
重建质量不等于后验准确

Noise Search

Ma et al., CVPR 2025

评价器引导噪声搜索
算力用于比较与优化候选

研究质量与预算的关系
不保证后验采样正确

推理文献二：用未来价值选择候选与路径

代表论文

主要贡献

条件与局限

Twisted Diffusion Sampler

Wu et al., NeurIPS 2023

近似 value 改善提议
完整 SMC 权重校正偏差

固定生成器的条件分布
粒子数增大时渐近正确

Feynman Kac Correctors

Skreta et al., ICML 2025

先指定整条密度曲线
再把 PDE 缺陷变成权重

边缘方程恒等式精确
仍有网格与粒子误差

FK Steering

Singhal et al., ICML 2025

把终端奖励分解为路径势
通过重采样分配探索预算

目标由完整势乘积决定
有限粒子仍可能退化

Soft Value Based Decoding

Li et al., NeurIPS 2025

从同一状态提出多个候选
按未来价值选择下一步

有限候选有选择偏差
MC 版仍需训练 value

推理文献三：怎样计算引导并校正偏差？

代表论文

主要贡献

条件与局限

DOIT

Zhu et al., ICML 2026

用 Monte Carlo 估计
Doob 动态修正

Proto 理论使用完整 rollout
Practical 另含代理误差

URGE

Wang et al., ICML 2026

用 Girsanov 路径权重
构造可计算的 SMC 权重

权重无需奖励导数
有限粒子并非精确采样

Two Queries / Stein

讲者研究稿

中心化值查询改善引导
保留完整路径供终端校正

依赖值函数、矩与曲率条件
下界针对每步全量重采样

单条路径的计算

网格步数与值查询数

独立探索的计算

完整轨迹数量

外层校正的计算

独立加权或 MH 迭代